

Análise de Gêneros de Filmes Usando Grafos de Similaridade de Diálogos

*Uma abordagem baseada em grafos para identificar gêneros cinematográficos a partir da análise de diálogos de filmes.

1st Henrique de Freitas Araújo
dept. Engenharia da Computação
CEFET-MG
Divinópolis, Brasil
hfreitas2607@gmail.com

Abstract—Este artigo apresenta uma análise de gêneros de filmes utilizando grafos de similaridade de diálogos. Determinamos o gênero dos filmes por meio da similaridade das linhas de diálogo entre dois filmes, formulando o peso de um diálogo para um gênero relacionado e criando um grafo de treinamento para, posteriormente, comparar o filme desejado com o grafo treinado. Os resultados demonstram a eficácia da metodologia na identificação dos gêneros cinematográficos, contribuindo para o avanço das técnicas de análise de filmes.

Index Terms—análise de filmes, grafos de similaridade, processamento de linguagem natural, classificação de gêneros, mineração de dados

I. INTRODUÇÃO

A indústria cinematográfica tem evoluído significativamente e, com ela, o volume de dados textuais, como scripts de filmes, que oferecem um vasto campo para a aplicação de técnicas avançadas de Processamento de Linguagem Natural (PLN). Esses dados são ricos em informações que podem ser exploradas para identificar padrões narrativos e realizar uma categorização mais precisa dos gêneros cinematográficos.

Neste trabalho, propomos uma abordagem inovadora que integra a modelagem dos dados em grafos com técnicas de similaridade semântica. Nossa metodologia não se limita à simples extração e representação dos diálogos, mas incorpora um robusto mecanismo de análise comparativa que avalia a relevância dos gêneros com base em cálculos precisos. Os principais componentes da nossa abordagem são:

- **Extração dos diálogos:** Processamento dos scripts para identificar e extrair os diálogos relevantes dos filmes.
- **Cálculo dos embeddings:** Utilização de modelos modernos, como o *Sentence Transformers*, para converter os diálogos em vetores densos que capturam nuances semânticas. Essa transformação permite calcular a similaridade semântica por meio do cosseno entre os embeddings.
- **Construção do grafo:** Representação dos diálogos como nós em um grafo, com arestas estabelecidas com base na similaridade semântica entre eles. O peso de cada aresta é determinado pela soma e pelo produto dos valores dos embeddings, refletindo a intensidade da conexão semântica.

- **Acumulação dos pesos e análise comparativa:** Os pesos acumulados para cada gênero são comparados com médias históricas obtidas a partir de um conjunto maior de filmes. Essa comparação é realizada por meio de cálculos percentuais, como:

– **Diferença percentual:** Utilizando a fórmula $\% \text{Diferença}_i = \left(\frac{V_{f,i} - V_{m,i}}{V_{m,i}} \right) \times 100$, onde $V_{f,i}$ representa o valor acumulado para o gênero i no filme atual e $V_{m,i}$ é o valor médio acumulado para o mesmo gênero.

– **Diferença percentual média:** Calculada como a média aritmética das diferenças percentuais de todos os gêneros, fornecendo um indicador global da acurácia da classificação.

Essa abordagem híbrida apresenta vantagens importantes:

- **Revelação de padrões semânticos não triviais:** A análise das similaridades entre os diálogos permite identificar conexões que evidenciam a predominância de determinados gêneros.
- **Integração incremental de novos dados:** O sistema possibilita a atualização contínua, incorporando novos filmes sem a necessidade de reprocessamento total.
- **Comparação robusta:** A metodologia comparativa, que utiliza cálculos percentuais para contrastar os valores acumulados com médias históricas, aprimora a precisão na inferência dos gêneros, permitindo uma análise mais justa e equilibrada.

Adicionalmente, os cálculos realizados — baseados na soma e no produto dos pesos dos embeddings — garantem que a influência de cada diálogo seja considerada de forma integrada, contribuindo para uma visão mais detalhada e refinada dos padrões narrativos presentes no filme. Dessa forma, nossa proposta não só se destaca por sua capacidade de classificar os gêneros com base em conexões semânticas, mas também por oferecer uma análise comparativa que contextualiza os resultados dentro de uma base de dados histórica, potencializando a validade dos padrões identificados.

Os resultados obtidos, que serão apresentados na seção de **Resultados e Discussão**, demonstram que, mesmo diante

dos desafios computacionais e de interpretação, a abordagem é promissora e capaz de revelar nuances significativas na categorização dos gêneros cinematográficos. Na **Conclusão**, discutiremos as principais descobertas e as perspectivas futuras para a otimização e aprimoramento da metodologia.

II. REFERENCIAL TEÓRICO

A utilização de grafos para modelar dados textuais possui vasta fundamentação na literatura. Diversos trabalhos clássicos demonstram a eficácia dessa abordagem para extrair e organizar informações a partir de relações implícitas nos textos. Destacamos, por exemplo:

- **TextRank** [3] – Utilizado para extração automática de palavras-chave, demonstrando como a modelagem em grafo pode identificar os termos mais relevantes em um texto.
- **PageRank** [4] – Originalmente aplicado na ordenação de páginas web, servindo de inspiração para métodos que ranqueiam elementos com base na conectividade.

Pesquisas recentes têm explorado a integração de técnicas de embeddings para representar sentenças e diálogos em espaços vetoriais densos. Por exemplo, o trabalho de [5] demonstra como modelos como o `all-MiniLM-L6-v2` podem capturar nuances semânticas que métodos baseados em frequências não conseguem identificar.

Nossa metodologia se diferencia ao adaptar algoritmos clássicos de exploração de grafos para o contexto de similaridade semântica, integrando conceitos clássicos e modernos. Neste sentido, os pontos principais que fundamentam nossa abordagem são:

A. Construção e Exploração do Grafo de Similaridade

O nosso método parte da transformação dos diálogos (ou textos) em embeddings, utilizando técnicas de PLN modernas. Cada diálogo é representado como um vetor em um espaço semântico, permitindo o cálculo de similaridade (por exemplo, utilizando a similaridade cosseno). Inspirando-se em métodos de **grafo de vizinhança** – em que nós são conectados se estiverem próximos no espaço métrico – aplicamos um limiar de similaridade (threshold) para estabelecer arestas ponderadas entre os nós. Essa abordagem é análoga à construção de grafos esparsos [6], conceito amplamente utilizado em algoritmos de clustering e *graph sparsification*.

B. Integração de Múltiplas Entidades e Agregação de Informação

Além de conectar diálogos entre si, nosso grafo incorpora outros tipos de nós, tais como:

- **Filmes:** Cada filme é representado por um nó e, para garantir a ligação semântica, todos os diálogos extraídos são conectados ao respectivo filme com uma aresta de peso unitário.
- **Gêneros:** Nós que representam gêneros são utilizados para agregar as contribuições provenientes dos diálogos. Ao percorrer os vizinhos de um diálogo, são identificadas conexões que estabelecem relações entre os elementos

textuais e os gêneros, sendo os pesos das arestas combinados (por meio de multiplicação e acumulação) para inferir a relevância semântica de cada gênero.

Essa estrutura, que remete a uma representação **bipartida** ou heterogênea – comum em sistemas de recomendação – permite a propagação de informações locais através de técnicas de *message passing* [7].

C. Adaptação de Algoritmos Clássicos para o Contexto Semântico

Embora algoritmos como **BFS** [8] e **Dijkstra** [9] sejam tradicionalmente empregados para encontrar caminhos de menor custo em grafos, nossa abordagem adapta a ideia central desses algoritmos para realizar a acumulação de pesos (ou “mensagens”) que representam os níveis de similaridade. Em vez de buscar o caminho mínimo, o método percorre o grafo conectando diálogos, filmes e gêneros, acumulando e ponderando os pesos das arestas de forma a captar a influência semântica de cada diálogo. Essa estratégia também se assemelha aos mecanismos utilizados em **Graph Neural Networks** [10], onde a agregação de informações locais possibilita a formação de uma visão global mais robusta.

D. Justificativa e Impacto da Abordagem Híbrida

A escolha de integrar modelagem em grafos com representações de embeddings proporciona diversas vantagens:

- **Captura da Similaridade Semântica:** Ao representar diálogos em espaços vetoriais e conectar nós com base na similaridade cosseno, é possível capturar relações semânticas mais refinadas do que aquelas obtidas por métodos baseados apenas em contagem de termos ou frequências.
- **Agregação de Informações Heterogêneas:** A utilização de nós que representam filmes e gêneros permite a agregação de informações de diferentes fontes, facilitando inferências robustas sobre a classificação dos gêneros cinematográficos.
- **Flexibilidade e Escalabilidade:** Modelar o problema como um grafo permite a inclusão incremental de novos dados e a aplicação de algoritmos otimizados (como os já disponíveis no NetworkX), além de possibilitar a exportação para ferramentas de visualização, como o Gephi.

Estudos que correlacionam mineração de dados, PLN e análise de redes reforçam a eficácia dessa abordagem híbrida. A integração entre:

- A modelagem em grafos para capturar relações estruturais;
- Os embeddings para representar a semântica dos diálogos;
- E a adaptação de algoritmos clássicos para a acumulação e propagação de pesos;

cria um sistema capaz de revelar padrões e relações ocultas nos scripts cinematográficos, contribuindo para avanços significativos na classificação dos gêneros.

E. Síntese

Nossa abordagem combina a modelagem clássica de grafos com embeddings modernos para criar uma rede que conecta diálogos, filmes e gêneros por meio de arestas ponderadas (definidas por limiares de similaridade). Adaptamos algoritmos tradicionais para acumular esses pesos, capturando relações semânticas profundas e revelando padrões ocultos nos scripts cinematográficos, o que garante robustez à metodologia.

III. METODOLOGIA

Nesta seção, detalhamos a abordagem adotada para inferir os gêneros de um filme com base nas conexões semânticas dos diálogos, utilizando os metadados presentes no arquivo `clean_parsed_vote_meta.json`.

A. Carregamento dos Metadados e Localização dos Arquivos

A base de dados utilizada deriva do *Movie-Script-Database* [11], que agrega mais de 2.5 mil scripts de filmes em formato .txt, acompanhados dos metadados oriundos de fontes como TMDb e IMDb. O arquivo JSON consolida informações essenciais (título, data de lançamento, classificação, gêneros, etc.), enquanto os scripts processados são armazenados na pasta `scripts/parsed/tagged`, obedecendo a uma estrutura padronizada.

B. Extração dos Diálogos

A extração dos diálogos é realizada a partir dos arquivos `tagged`, onde cada linha iniciada por "D:" representa um diálogo. Esse procedimento inclui também uma etapa de filtragem para remover entradas irrelevantes, garantindo a obtenção apenas dos dados necessários para a análise semântica. O trecho a seguir exemplifica esse processo:

```
with open(caminho_completo, 'r', encoding='utf-8')
as file:
    lines = file.readlines()
    dialogues = [line[2:].strip() for line in lines if
    line.startswith('D:')]
```

Listing 1: Extração dos diálogos do arquivo `tagged`

C. Construção do Grafo de Similaridade e Integração dos Gêneros

A construção do grafo é organizada em quatro etapas principais:

1) Adição dos Nós para o Filme e Gêneros:

Inicialmente, adicionamos um nó para o filme (título) e, para cada gênero listado, criamos um nó correspondente. As conexões são estabelecidas via arestas rotuladas como `title_to_genre`:

```
if not G.has_node(titulo):
    G.add_node(titulo, type='title')
for genero in generos:
    if not G.has_node(genero):
        G.add_node(genero, type='genre')
    if not G.has_edge(titulo, genero):
        G.add_edge(titulo, genero,
                    label='title_to_genre')
```

Listing 2: Adição do nó do filme e gêneros

2) Extração e Filtragem dos Diálogos:

Extraímos os diálogos do arquivo `tagged` e aplicamos uma filtragem para eliminar entradas irrelevantes, utilizando funções que se valem de `SentenceTransformer` e `spaCy`:

```
dialogues = [line[2:].strip() for line in
    lines if line.startswith('D:')]
filtered_dialogues = [d for d in dialogues if
    not is_irrelevant(d)]
```

Listing 3: Extração e filtragem de diálogos

3) Cálculo de Similaridades e Criação de Arestas:

A partir dos diálogos filtrados, são calculados os embeddings e comparados os pares de diálogos. Para aqueles com similaridade superior a um limiar (por exemplo, 0.85), criamos arestas com peso correspondente:

```
for i, dialogue_a in
    enumerate(filtered_dialogues):
    for j, dialogue_b in
        enumerate(filtered_dialogues):
        if i < j:
            similarity =
                util.pytorch_cos_sim(embeddings[i],
                embeddings[j]).item()
            if similarity > 0.85:
                G.add_edge(dialogue_a,
                    dialogue_b,
                    weight=similarity,
                    label='similarity')
```

Listing 4: Criação de arestas entre diálogos

4) Integração dos Diálogos ao Filme e Gêneros:

Cada diálogo considerado relevante é incorporado ao grafo e conectado ao nó do filme por meio de uma aresta `dialogue_to_title`. Além disso, o diálogo é associado a cada gênero, com o peso da aresta ajustado conforme a relevância:

```
for dialogue in relevant_dialogues:
    if not G.has_node(dialogue):
        G.add_node(dialogue, type='dialogue')
    if not G.has_edge(dialogue, titulo):
        G.add_edge(dialogue, titulo,
                    label='dialogue_to_title')
    for genero in generos:
        if G.has_edge(dialogue, genero):
            G[dialogue][genero]['weight'] +=
                max(1,
                    dialogue_counts.get(dialogue, 0))
        else:
            G.add_edge(dialogue, genero,
                        label='dialogue_to_genre',
                        weight=max(1,
                            dialogue_counts.get(dialogue,
                                0)))
```

Listing 5: Integração dos diálogos com o filme e gêneros

Após essas etapas, o grafo representa de forma robusta as relações semânticas entre o filme, seus diálogos e os gêneros, possibilitando uma análise aprofundada.

D. Visualização da Estrutura do Grafo

A estrutura do grafo contempla três tipos de nós:

- **Filme (Título):** Nó representativo do filme analisado.
- **Diálogo:** Nós que armazenam os diálogos extraídos.
- **Gênero:** Nós que correspondem aos gêneros cinematográficos.

As arestas conectam esses nós conforme as relações:

- **title_to_genre:** Liga o filme aos seus gêneros;
- **dialogue_to_title:** Associa cada diálogo ao filme;
- **dialogue_to_genre:** Conecta diálogos aos gêneros, com o peso refletindo a relevância;
- **similarity:** Une diálogos com alta similaridade semântica.

A Figura 1 ilustra o grafo completo com adição de poucos filmes, e a Figura 2 apresenta uma imagem simplificada da estrutura.




Fig. 1: Representação gráfica do grafo completo com o filme, gêneros e diálogos.




Fig. 2: Representação simplificada da estrutura do grafo com nós de filmes, diálogos e gêneros.

E. Inferência dos Gêneros via Similaridade Semântica

A inferência dos gêneros é efetuada pela acumulação dos pesos das arestas que conectam os diálogos aos nós de gênero. Inspirado em algoritmos como BFS e Dijkstra, o procedimento não busca o caminho mínimo, mas agrega a influência de cada diálogo diretamente:

- **Atualização dos Embeddings:** Os diálogos são processados com modelos pré-treinados (ex.: all-MiniLM-L6-v2), garantindo consistência na comparação.

- **Associação Direta ao Filme:** Cada diálogo é conectado ao filme com peso unitário (1.0), se ainda não o tiver.
- **Acumulação das Contribuições:** O grafo é percorrido a partir dos nós de diálogo, acumulando as contribuições para os gêneros com base na multiplicação dos pesos das arestas.

O exemplo a seguir ilustra a acumulação das contribuições:

```
for dialogue in dialogues:
    total_contrib = 0
    for neighbor in G.neighbors(dialogue):
        sim = G[dialogue][neighbor].get('weight', 0)
        for genre in genre_percentages.keys():
            if G.has_edge(neighbor, genre):
                genre_weight =
                    G[neighbor][genre].get('weight', 0)
                contrib = sim * genre_weight
                genre_percentages[genre] += contrib
    total_contrib += contrib
```

Listing 6: Acumulação das contribuições de cada diálogo para os gêneros

Após a acumulação, o grafo é exportado em formato GEXF para facilitar a visualização e análise em ferramentas como o Gephi.

F. Visualização dos Diálogos no Grafo

A Figura 3 apresenta a representação dos diálogos no grafo, com cores que diferenciam os tipos de nós:

- **Roxo:** Novos diálogos sem conexões estabelecidas;
- **Preto:** Novos diálogos que já conseguiram estabelecer conexões;
- **Laranja:** Nó representando o filme adicionado para análise;
- **Azul:** Gêneros cinematográficos previamente incorporados;
- **Verde:** Diálogos de filmes já existentes no grafo.

A análise visual evidencia:

- Uma região central densa, indicando grupos de diálogos altamente conectados;
- Nós isolados na periferia, sugerindo diálogos com poucas conexões;
- Uma estrutura consolidada entre gêneros e diálogos, evidenciada pelas regiões azul e verde.




Fig. 3: Grafo de diálogos com diferentes tipos de vértices representados por cores distintas.

G. Persistência dos Dados de Contribuição dos Gêneros

Para garantir a continuidade da análise, os dados acumulados relativos às contribuições dos gêneros e o número de filmes processados são salvos em um arquivo externo (`cumulative_data.json`). Esse mecanismo permite:

- **Persistência dos Dados:** Informações preservadas mesmo após o encerramento do sistema.
- **Atualização Incremental:** Cada nova análise atualiza os totais acumulados, refinando as médias de forma contínua.
- **Facilidade de Integração:** O formato JSON facilita a integração com outras ferramentas e a visualização externa dos resultados.

As funções `load_cumulative_data()` e `save_cumulative_data()` gerenciam, respectivamente, o carregamento e o salvamento dos dados, permitindo que as análises futuras retomem a partir do estado previamente armazenado.

H. Análise Comparativa dos Gêneros

Para avaliar a representatividade dos gêneros do filme atual em relação à média acumulada, utilizam-se as seguintes métricas:

1) *Diferença Percentual por Gênero:* A diferença percentual para cada gênero é calculada pela fórmula:

$$\% \text{Diferença}_i = \left(\frac{V_{f,i} - V_{m,i}}{V_{m,i}} \right) \times 100 \quad (1)$$

Onde:

- $V_{f,i}$: Valor do gênero i no filme atual;
- $V_{m,i}$: Valor médio acumulado do gênero i .

2) *Diferença Percentual Média:* A diferença percentual média é definida como a média aritmética das diferenças percentuais absolutas de todos os gêneros:

$$\% \text{Diferença Média} = \frac{1}{N} \sum_{i=1}^N |\% \text{Diferença}_i| \quad (2)$$

Sendo N o número total de gêneros analisados.

I. Resumo do Fluxo de Processamento

O fluxo geral da análise é resumido nos seguintes passos:

- 1) Leitura do arquivo `clean_parsed_vote_meta.json` para obtenção dos metadados e dos caminhos dos arquivos `tagged`.
- 2) Extração dos diálogos dos arquivos `tagged`.
- 3) Construção do grafo com nós representando o filme, os diálogos e os gêneros, e estabelecimento de arestas com pesos baseados na similaridade semântica.
- 4) Acumulação dos pesos das conexões para inferir os gêneros predominantes.

IV. RESULTADOS E DISCUSSÃO

Neste trabalho, propusemos uma abordagem inovadora para a classificação dos gêneros de filmes por meio da análise semântica dos diálogos e da construção de grafos de similaridade. Essa metodologia possibilita a extração de padrões e a identificação de relações entre os diálogos, oferecendo uma nova perspectiva para a categorização cinematográfica.

A. Fluxo de Processamento e Análise dos Dados

O processamento inicia com a extração dos diálogos dos scripts, seguido pela construção de um grafo onde:

- **Representação dos diálogos:** Cada nó do grafo corresponde a um diálogo extraído dos scripts dos filmes, capturando as informações semânticas inerentes às falas dos personagens.
- **Definição das conexões:** As arestas são estabelecidas com base na similaridade semântica entre os diálogos, calculada a partir da combinação dos pesos dos embeddings.
- **Filtragem por limiar:** Apenas pares de diálogos com similaridade acima de um limiar predefinido são considerados, garantindo a relevância das conexões.

A Figura 4 ilustra detalhadamente o fluxo de processamento adotado – desde a extração dos diálogos até a construção do grafo – para que o leitor compreenda como os dados brutos são transformados em conexões semânticas. enfatizamos a importância da etapa de pré-processamento e a maneira como os embeddings são combinados para calcular as similaridades.




Fig. 4: Fluxo de processamento.

De maneira complementar, a Figura 5 apresenta uma comparação visual entre os valores acumulados de similaridade, a média acumulada e a diferença percentual para cada gênero cinematográfico. Esse gráfico possibilita a identificação de padrões de correlação entre os gêneros e a distribuição dos pesos ao longo dos dados analisados. Gêneros com valores significativamente mais altos, como **Drama** e **Romance**, sugerem uma forte correspondência semântica com os diálogos

extraídos, enquanto aqueles com valores mais baixos indicam uma menor associação dentro do contexto analisado. Além disso, a inclusão da diferença percentual (representada em verde) permite uma rápida avaliação das discrepâncias entre a similaridade acumulada e a média, destacando possíveis desvios que podem indicar vieses ou particularidades na distribuição dos dados.




Fig. 5: Comparação dos valores de pesos calculados para cada gênero, evidenciando as variações e correlações semânticas entre as categorias.

A Figura 6 mostra a diferença percentual entre a similaridade acumulada e a média por gênero. Gêneros como *Música* e *Mistério* exibem percentuais elevados (pesos acima da média), enquanto *Western* e *Documentário* apresentam valores negativos (menor correlação semântica), facilitando a identificação de discrepâncias sutis.




Fig. 6: Distribuição da diferença percentual entre a similaridade acumulada e a média por gênero, destacando variações relevantes na correlação semântica dos diálogos analisados.

Por meio dessas visualizações, é possível compreender melhor como os gêneros se relacionam semanticamente com os diálogos estudados, permitindo uma análise mais aprofundada sobre padrões narrativos e sua relevância dentro do escopo da pesquisa.

B. Análise do Grafo Completo dos 236 Filmes

Além da análise detalhada do fluxo de processamento e dos valores acumulados por gênero, a nossa metodologia foi

aplicada a um grafo robusto que consolida os diálogos de 236 filmes. Essa abordagem ampliada permite capturar uma visão mais abrangente das inter-relações semânticas presentes no universo cinematográfico analisado.

A Figura 1 apresenta o grafo completo, onde:

- Cada nó representa um diálogo extraído dos scripts dos 236 filmes;
- As arestas conectam diálogos que apresentam similaridade semântica superior aos limiares definidos (0.70 para diálogos internos e 0.65 para diálogos provenientes de conjuntos externos).




Fig. 7: Grafo completo dos 236 filmes: visualização das conexões semânticas entre os diálogos.

Essa visualização permite identificar agrupamentos e clusters que refletem tendências temáticas e padrões comuns entre os filmes. Por exemplo, a concentração de nós em determinadas regiões do grafo pode indicar subgêneros ou a forte presença de elementos característicos de certos gêneros. É importante ressaltar que o grafo não é completamente balanceado, uma vez que há maior representação de filmes de certos gêneros, o que pode ser atribuído tanto ao viés inerente na base de dados quanto aos parâmetros de seleção (threshold) que favorecem a inclusão de mais diálogos de filmes com características marcantes.

Em síntese, a integração das visualizações – tanto do fluxo de processamento quanto do grafo completo – fornece uma visão integrada e detalhada da metodologia aplicada, demonstrando como os dados são transformados, processados e visualizados para a classificação dos gêneros cinematográficos.

C. Desafios, Estratégias de Otimização e Implementação do Cálculo de Desvio

Embora os resultados sejam promissores, alguns desafios se destacam nesta abordagem:

- 1) **Alto Consumo Computacional:** A comparação exaustiva entre os diálogos demanda recursos intensivos, pois cada diálogo é avaliado em relação a todos os demais.

- 2) **Ambiguidade na Classificação:** Filmes que combinam elementos de diferentes gêneros podem apresentar diálogos semanticamente próximos, dificultando a definição do gênero predominante.
- 3) **Viés na Base de Dados:** O desbalanceamento na quantidade de diálogos por gênero pode favorecer categorias com maior representação, impactando a pontuação acumulada.

Para mitigar essas limitações, foram adotadas estratégias de normalização dos valores e otimização dos algoritmos de comparação. Uma melhoria significativa foi a incorporação do cálculo de desvio percentual em relação à média acumulada, permitindo uma comparação mais refinada entre o filme analisado e os dados de referência.

Exemplo Resumido dos Resultados Obtidos:

Em vez de apresentar a totalidade dos resultados, destacamos apenas alguns gêneros que evidenciam a eficácia do método, abaixo seguem alguns dados retirados da análise do filme *Blow* [12]:

- **Drama:** Valor acumulado de 6573.22 – Diferença de 46.70% (Desvio de 118.06%);
- **Mystery:** Valor acumulado de 1899.85 – Diferença de 48.22% (Desvio de 125.15%);
- **Comedy:** Valor acumulado de 2695.15 – Diferença de 26.43% (Desvio de 23.41%);
- **Animation:** Valor acumulado de 318.78 – Diferença de -8.83% (Desvio de -141.21%).

Nesta análise, gêneros que apresentam diferenças percentuais significativamente acima da média (21.42%) indicam uma forte correlação com os padrões semânticos do filme. Assim, categorias como *Drama* e *Mystery* se destacam, enquanto valores negativos em gêneros como *Animation* sugerem menor relevância para o contexto analisado.

D. Análise dos Dados Agregados e Impacto dos Parâmetros de Seleção

Além dos resultados individuais, nossa análise também incorpora dados agregados a partir de múltiplos filmes. O arquivo `cumulative_genre_totals` consolida os totais acumulados dos gêneros a partir de 6 filmes, apresentando valores como:

- **Drama:** 26884.08
- **Comedy:** 12790.43
- **Thriller:** 13694.03
- **Crime:** 11262.73

Esses totais fornecem uma base para a média acumulada, que, conforme mais filmes são analisados, tende a se tornar mais robusta, permitindo comparações mais precisas entre o filme atual e a base de dados. A média das diferenças percentuais é utilizada para normalizar os valores e destacar os desvios que indicam maior ou menor relevância dos gêneros.

Adicionalmente, o grafo resultante abrange diálogos de 236 filmes, o que enriquece significativamente nossa análise. No entanto, esse grafo não é completamente balanceado, pois há maior representação de filmes de certos gêneros – um reflexo

tanto do volume dos diálogos quanto do viés presente na base de dados. Essa disparidade é agravada pelos valores de *threshold* utilizados na seleção dos pares de diálogos.

Para filtrar os diálogos com relevância semântica, adotamos os seguintes parâmetros:

- Para diálogos do mesmo conjunto, somente são considerados pares cuja similaridade excede 0.70;
- Para diálogos provenientes de conjuntos externos, o limite é de 0.65.

Conforme parte do código utilizado:

```
if similarity > 0.70:
    relevant_pairs.append((dialogue_a,
                           dialogue_b, similarity))
```

Esses limiares asseguram que apenas as conexões semanticamente relevantes contribuam para os totais acumulados, ampliando o número de diálogos incorporados na análise e, consequentemente, enriquecendo a robustez dos resultados. Esse processo, embora computacionalmente intensivo, permite que a comparação entre o filme analisado e a média acumulada seja mais representativa dos padrões semânticos observados.

Por fim, o grafo, que foi exportado para o Gephi (arquivo `grafo_generos.gexf`), oferece uma visão visual das conexões entre os diálogos, complementando a análise quantitativa com insights gráficos sobre a distribuição dos gêneros e as relações semânticas. Essa abordagem integrada – que une dados agregados, cálculos de desvio e visualização em grafo – representa um avanço na categorização dos gêneros cinematográficos, permitindo identificar nuances e tendências que os métodos tradicionais podem não capturar.

V. CONCLUSÃO

Este trabalho apresentou uma abordagem inovadora para a classificação de gêneros cinematográficos baseada na análise semântica dos diálogos, por meio da construção de grafos de similaridade e da comparação dos valores acumulados com médias históricas. Os resultados obtidos para o filme *Blow* evidenciam que o método é capaz de revelar padrões semânticos consistentes e diferenciais marcantes entre os gêneros, apesar dos desafios computacionais e de normalização existentes.

Os principais achados e contribuições deste estudo podem ser resumidos em:

• Eficácia na Classificação:

- Os valores acumulados para os gêneros (ex.: Comedy: 2695.15, Drama: 6573.22, entre outros) quando comparados com as médias (ex.: Comedy: 2131.74, Drama: 4480.68) evidenciam diferenças percentuais expressivas, como 26.43% para Comedy e 46.70% para Drama.
- Essa diferenciação confirma que os gêneros que compõem a classificação original do filme, por exemplo, Crime e Drama, se destacam significativamente em relação aos demais.

• Cálculo de Desvio:

- A comparação percentual entre os valores do filme e a média acumulada, somada ao cálculo do desvio

em relação à média das diferenças (21.42%), fornece uma métrica robusta para identificar quais gêneros apresentam discrepâncias significativas.

- Gêneros como Music (diferença de 66.53% com desvio de 210.64%) e os casos em que os valores apresentam desvios negativos (como Animation e Family) ajudam a sinalizar potenciais áreas de refinamento no modelo.

• Visualização e Interpretação dos Resultados:

- A exportação do grafo para o Gephi (como 'grafo_generos.gexf') e os diagramas comparativos possibilitam uma visualização clara do fluxo de processamento e dos padrões semânticos, facilitando a interpretação dos resultados.

• Desafios e Oportunidades de Melhoria:

- O elevado consumo computacional devido à comparação de inúmeros pares de diálogos destaca a necessidade de otimizações, como a implementação de técnicas de amostragem ou algoritmos aproximados.
- A normalização dos valores médios deve ser aprimorada para mitigar o viés decorrente de bases de dados desbalanceadas e para ajustar melhor as comparações percentuais.

Adicionalmente, a análise comparativa mostrou que:

- A metodologia consegue atribuir pontuações significativamente superiores aos gêneros que efetivamente compõem a classificação original do filme *Blow*, reforçando a correlação semântica identificada.
- O cálculo do desvio oferece uma perspectiva adicional sobre a variabilidade dos resultados, permitindo ajustes finos e a identificação de possíveis subgêneros ou nuances não capturadas pelos métodos convencionais.

Dentre as perspectivas para trabalhos futuros, destacam-se:

- **Otimização Computacional:** Investir na redução do custo computacional por meio da implementação de algoritmos mais eficientes ou técnicas de amostragem.
- **Aprimoramento da Normalização:** Desenvolver métodos mais sofisticados para normalizar os valores acumulados, reduzindo o viés e ajustando a comparação com as médias históricas.
- **Expansão da Base de Dados:** Incluir um volume maior e mais diversificado de filmes, o que permitirá validar a robustez do método e possivelmente revelar novos subgêneros.
- **Integração de Métricas Complementares:** Explorar a combinação de outras métricas de similaridade e de análise semântica para enriquecer a interpretação dos resultados.

Em síntese, a integração de técnicas modernas de PLN com algoritmos clássicos adaptados para a acumulação de pesos semânticos demonstra ser uma abordagem promissora para a classificação dos gêneros cinematográficos. Embora desafios relacionados ao consumo computacional e à normalização dos dados ainda precisem ser superados, os resultados para

o filme *Blow* evidenciam a eficácia do método e apontam para um potencial significativo de refinamento e aplicação em larga escala. Essa metodologia não só permite uma melhor correspondência com as categorias tradicionais, mas também abre caminho para a descoberta de novas nuances e subgêneros a partir da análise dos diálogos.

REFERENCES

- [1] H. de Freitas Araújo, "Shield: Análise de gêneros cinematográficos via grafos e pln," 2025, acessado em: February 10, 2025. [Online]. Available: <https://github.com/Ak4ai/SHIELD>
- [2] H. d. F. Aveek Saha, "Movie script database imdb, tagged archives," https://zenodo.org/records/14841817?token=eyJhbGciOiJIUzUxMiJ9.eyJpZCI6ImEyNmJjYjY4LTJiNTQtNGU2MS1iNjVkbGkYmJlNDVhYjZlNiIsImRhdDkiOiJmMwEzPi44aWQkUjXq2X8GVFbvp-juyDdYofeCwGZIDYv6A_A3wwqySuZnJ_9-3YOCeIN3QoGzITJ8rt9SQSw, 2025, zENODO.
- [3] R. Mihalcea and P. Tarau, "Textrank: Bringing order into texts," in *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, 2004, pp. 404–411.
- [4] L. Page, S. Brin, R. Motwani, and T. Winograd, "The pagerank citation ranking: Bringing order to the web," *Technical Report, Stanford InfoLab*, 1999, available online: <http://ilpubs.stanford.edu:8090/422/>.
- [5] N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," *arXiv preprint arXiv:1908.10084*, 2019.
- [6] D. A. Spielman, *Spectral Graph Theory*. Providence, RI: American Mathematical Society, 2011.
- [7] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, and G. E. Dahl, "Neural message passing for quantum chemistry," in *Proceedings of the 34th International Conference on Machine Learning*. Sydney, Australia: PMLR, 2017, pp. 1263–1272.
- [8] E. W. Dijkstra, "A note on two problems in connexion with graphs," 1959, disponível em: <https://www.cs.utexas.edu/users/EWD/ewd02xx/EWD215.PDF>.
- [9] —, "A note on two problems in connexion with graphs," *Numerische Mathematik*, vol. 1, pp. 269–271, 1959.
- [10] F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, and G. Monfardini, "The graph neural network model," *IEEE Transactions on Neural Networks*, vol. 20, no. 1, pp. 61–80, 2009.
- [11] A. Saha, "Movie-script-database," <https://github.com/Aveek-Saha/Movie-Script-Database>, 2020, repositório GitHub.
- [12] "Profissão de risco," 2001, disponível em: <https://www.imdb.com/title/tt0221027/>.